金融大数据处理技术作业5(任务一)

221275010 屈航

1、设计思路

1.1、 Mapper的设计思路

Mapper 重构了一个 map 函数。

对于 analyst_ratings.csv 里面每一行数据的处理要抽出来**最后一个字段** stock。这可以采 string.split(",") 把最后一个字段 stock 提取出来,然后加入 context.write(stock, 1)。

以下是 map 函数的主要功能语句:

```
tring line = value.toString();
String[] columns = line.split(","); // Assuming CSV format with ',' as delimiter
if (columns.length >= 4) { // Ensure there are enough columns
    stockCode.set(columns[columns.length - 1].trim()); // Assuming stock code is
in the last column
    context.write(stockCode, one);
}
```

注意:实验开始前要对 analyst_ratings.csv 中的第一行删去,第一行并不是需要统计的内容。

1.2、Reducer的设计思路

Reducer 包含有 reduce 函数和 cleanup 函数。

1. reduce **函数**就是实现对于同一个key的 Iterable<Intwritable> values 中的每一个元素也就是统计数求和,最后再将求和结果存入一个叫做 Map<String,Integer> stockCountMap = new HashMap<>() 的类里面以待 cleanup 函数实现对输出格式的处理。以下是 reduce 函数的主要功能语句:

```
int sum = 0;
for (IntWritable val : values) {
    sum += val.get();
}
stockCountMap.put(key.toString(), sum);
```

2. cleanup **函数**就是实现对输出结果的格式控制。首先建立一个列表 List<Map.Entry<String, Integer>> sortedList = new ArrayList<>(stockCountMap.entrySet()),然后通过**重构** sort **方法**的比较方法实现按照**词频**进行**倒序排列**;最后按照排序好的 sortedList 依次按照格式进行输出。

以下是 cleanup 函数的主要功能语句:

```
List<Map.Entry<String, Integer>> sortedList = new ArrayList<>
  (stockCountMap.entrySet());
sortedList.sort((a, b) -> b.getValue().compareTo(a.getValue())); // Sort by
count descending

// Output the results in the required format
int rank = 1;
for (Map.Entry<String, Integer> entry : sortedList) {
    context.write(new Text(rank + ": " + entry.getKey() + ", " +
    entry.getValue()), null);
    rank++;
}
```

1.3、项目运行的配置设计

- 此次项目主要使用 Maven 进行项目管理,通过编辑 pom.xml 文件对该项目进行配置。 pom.xml 文件的配置信息包含有该项目需要哪些库文件需要下载,该项目的项目文件有哪些。
- 依次使用 mvn clean install 进行配置,同时还可以使用 mvn compile 对 .class 文件进行生成, mvn package 实现对项目文件的 .class 文件打包成 jar 文件。
- 将 analyst_ratings.csv 上传至**HDFS**的 / input 文件夹里面,最后运行该项目的 jar 文件,运行命令为:

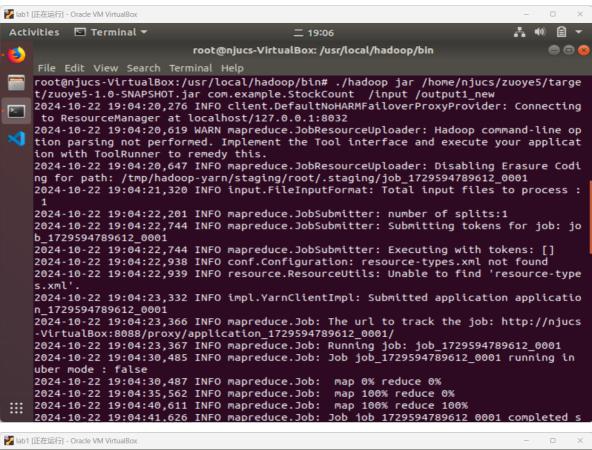
```
./hadoop jar /home/njucs/zuoye5/target/zuoye5-1.0-SNAPSHOT.jar
com.example.StockCount /input /output
```

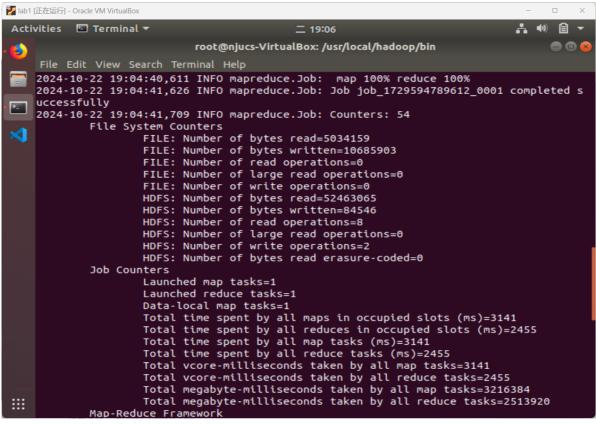
<u>注意要把导出来的 part-r-00000解锁,以实现普通用户可以打开,命令如下:</u>

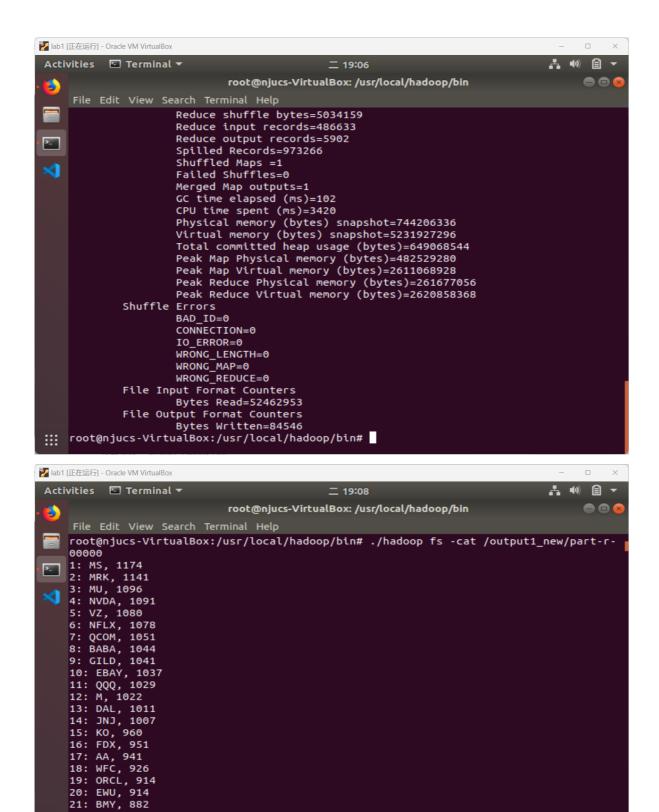
```
sudo chown $USER part-r-00000
```

2、程序运行结果

以下即为 StockCount.java 程序执行的任务一(统计数据集上市公司股票代码("stock"列)的出现次数,按出现次数从大到小输出,输出格式为"<排名>: <股票代码>, <次数>")的运行结果:







3、WEB页面截图

22: HD, 875 23: JCP, 865 24: BBRY, 858 25: EWJ, 848 26: AGN, 833 27: GPRO. 827

