## 金融大数据处理技术作业5(任务二)

221275010 屈航

### 1、设计思路

### 1.1、 Mapper的设计思路

Mapper 包含有 setup 函数和 map 函数。

1. Mapper **重构了一个** setup **函数。**该函数的主要作用是将缓存区的停词文件的内容存入 Mapper 类的集合变量 private HashSet<String> stopWords = new HashSet<>() 里面,为了后来的 map函数对 key 进行去除停词操作。

获得**缓存文件路径**可以用 context.getLocalCacheFiles() 实现,然后依据该路径建立一个 FileReader 指针**读取缓存文件**的内容,读取的内容暂存在 BufferedReader 当中,最后读取缓存 内容将每一个停词**依次存入** stopwords 当中。

以下是 setup 函数的主要功能语句:

```
Path[] stopWordPaths = context.getLocalCacheFiles();
if (stopWordPaths != null && stopWordPaths.length > 0) {
    try (BufferedReader br = new BufferedReader(new
FileReader(stopWordPaths[0].toString()))) {
        String line;
        while ((line = br.readLine()) != null) {
            stopWords.add(line.trim().toLowerCase());
        }
    }
}
```

2. Mapper **重构了一个** map **函数。**对于 analyst\_ratings.csv 里面每一行数据的处理要抽出来第二个个字段"headline"。

这可以采**正则表达式** String regex = ",(?=(?:[^\"]\*\"[^\"]\*\")\*[^\"]\*\$)"把第二个字段 headline 提取出来;

对于将**所有字母取小写**和**去掉多余空格**操作可以用 string..trim().toLowerCase()方法实现;

然后再用一次**正则表达式** "[^a-zA-z0-9]" 把 headline 里面的**单词提取**出来并放入一个数组 string [] 里面;

最后在 context.write(word, one) 之前检索一下 word 是否在停词文件里面,如果在的话就 continue, 并不写入 context。

注意 1: 实验开始前要对 analyst\_ratings.csv 中的第一行删去,第一行并不是需要统计的内容。

注意 2: split(",") 是不可以将 analyst\_ratings.csv 里面的 headline 字段分出来的,因为 headline 字段里面也有不少 ","。那样会截取出不完整的 headline ,必须要使用正则表达式 String regex = ",(?=(?:[^\"]\*\"[^\"]\*\"]\*\")\*[^\\"]\*\$)" 才能将 headline 完整提取出来。这一点很重要!

以下是 map 函数的主要功能语句:

### 1.2、Reducer的设计思路

Reducer 包含有 reduce 函数和 cleanup 函数。

1. reduce **函数**就是实现对于同一个key的 Iterable<Intwritable> values 中的每一个元素也就是统计数求和,最后再将求和结果存入一个叫做 TreeMap<Integer,String> countMap = new TreeMap<>() 的类里面以待 cleanup 函数实现对输出格式的处理。

注意: 这里其实将 key 和 value 翻了过来,这样可以更加方便的直接在后面使用关于 value 也就是词频的倒序排序。

以下是 reduce 函数的主要功能语句:

```
int sum = 0;
for (IntWritable val : values) {
    sum += val.get();
}
countMap.put(sum, key.toString());
```

2. cleanup **函数**就是实现对输出结果的格式控制。因为在 reduce 函数中将**键值颠倒存储**了,所有可以直接调用 Map.Entry<Integer,String> entry:

countMap.descendingMap().entrySet()方法实现关于key也就是词频的倒序排列;

该方法返回的是一个**倒序列表**,所以对于该倒序列表只需要 context.write 前100个字段即可,设置一个 for 循环, rank=1,最终只输出前100个即可退出循环,输出的每一个字段的 key 是 new Text(rank + ": " + entry.getValue() + ", " + entry.getKey(), value 为 null 即可完成格式修改。

以下是 cleanup 函数的主要功能语句:

```
int rank = 1;
for (Map.Entry<Integer, String> entry : countMap.descendingMap().entrySet())
{
   if (rank > 100) break;
   context.write(new Text(rank + ": " + entry.getValue() + ", " +
   entry.getKey()), null);
   rank++;
}
```

<u>注意: main 函数接口中需要添加 job.addCacheFile(new Path(args[2]).toUri()); 实现将缓存文件的参数也能传入至该程序的运行。</u>

#### 1.3、项目运行的配置设计

• 此次项目主要使用 Maven 进行项目管理,通过编辑 pom.xml 文件对该项目进行配置。 pom.xml 文件的配置信息包含有该项目需要哪些库文件需要下载,该项目的项目文件有哪些。

- 依次使用 mvn clean install 进行配置,同时还可以使用 mvn compile 对 .class 文件进行生成, mvn package 实现对项目文件的 .class 文件打包成 jar 文件。
- 将 analyst\_ratings.csv 上传至**HDFS**的 / input 文件夹里面, stop-word-list.txt 存入HDFS 的 / user/root 文件夹里面,最后运行该项目的 jar 文件,运行命令为:

```
./hadoop jar /home/njucs/zuoye5_2/target/zuoye5_2-1.0-SNAPSHOT.jar
HighFrequencyWords2 /input /output2 /user/root/stop-word-list.txt
```

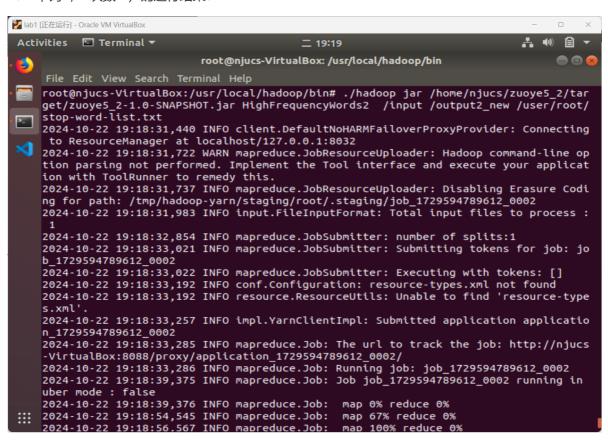
#### <u>注意要把导出来的 part-r-00000解锁,以实现普通用户可以打开,命令如下:</u>

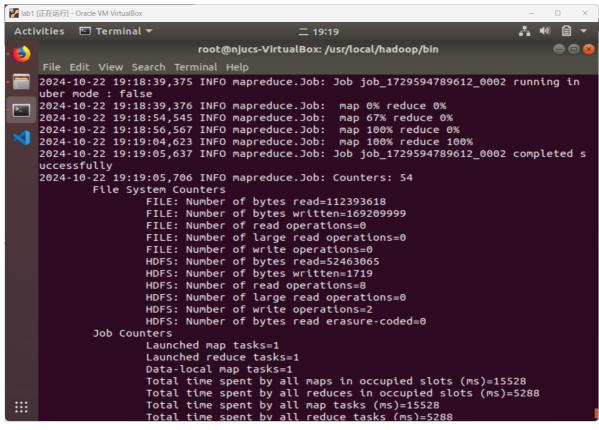
```
sudo chown $USER part-r-00000
```

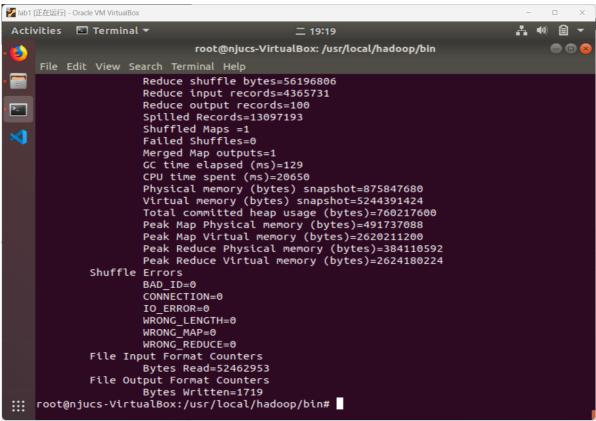
### 2、程序运行结果

以下即为 HighFrequencywords 2. java 程序执行的任务二(统计数据集热点新闻标题("headline" 列)中出现的前100个高频单词,按出现次数从大到小

输出。要求忽略大小写,忽略标点符号,忽略停词(stop-word-list.txt)。输出格式为"<排名>: <单词>, <次数>")的运行结果:







```
🗾 lab1 [正在运行] - Oracle VM VirtualBox
 Activities ☐ Terminal ▼
                                                                    二 19:08
                                                                                                                        å •0) 🖹 ▼
                                            root@njucs-VirtualBox: /usr/local/hadoop/bin
  3
       File Edit View Search Terminal Help
      root@njucs-VirtualBox:/usr/local/hadoop/bin# ./hadoop fs -cat /output1_new/part-r-
       00000
      1: MS, 1174
      2: MRK, 1141
3: MU, 1096
      4: NVDA, 1091
5: VZ, 1080
6: NFLX, 1078
      7: QCOM, 1051
8: BABA, 1044
      9: GILD, 1041
10: EBAY, 1037
11: QQQ, 1029
12: M, 1022
       13: DAL, 1011
      14: JNJ, 1007
15: KO, 960
16: FDX, 951
       17: AA, 941
18: WFC, 926
      19: ORCL, 914
20: EWU, 914
       21: BMY, 882
      22: HD, 875
23: JCP, 865
24: BBRY, 858
25: EWJ, 848
 ::: 26: AGN, 833
            GPRO.
```

# 3、WEB页面截图

